

Informatica per le Biotecnologie

Algoritmica Lezione 5-2

Studiato l'algoritmo per determinare la **edit distance** tra due sequenze, esamineremo ora **nuovi problemi di allineamento**

Ricerca approssimata di un pattern in un testo

Il pattern X e il testo Y sono sequenze di n e m caratteri, con $n \ll m$

La X può apparire in Y come **sottosequenza** S di questa, eventualmente con qualche differenza (la edit distance tra X e S può **non essere zero**)

La X può apparire in diversi punti di Y e vogliamo individuarli tutti

Adattiamo l'algoritmo ED:

$M[i,j]$ ora indica la edit distance tra
il prefisso $x_1 x_2 \dots x_i$ di X
e la sottosequenza $y_k y_{k+1} \dots y_j$ di Y
che termina in posizione **j** e minimizza
tale distanza (il valore $k \geq 1$ non è
noto a priori).

X: E A C E D R

$M[i,j] = 0$

				k				j		
Y	.	.	A	A	B	C	-	D	.	.
X			E	A	-	C	E	D	R	
			1					i		

L'unica variazione necessaria nell'algoritmo ED è inizializzare la riga zero con tutti 0

$$M[0, j] = 0, \quad \text{per } 0 \leq j \leq m$$

per assegnare edit distance zero a
l'allineamento tra il prefisso vuoto della X
e qualunque prefisso della Y

infatti X può apparire in qualsiasi punto di Y

I valori di output sono quelli **nell'ultima riga** della matrice, che indicano la minima edit distance tra la **X** e **tutte le sottosequenze della Y** che terminano in quella colonna

Tra questi valori si sceglieranno i più bassi, o quelli **con valore inferiore a un limite prefissato**.

	Ø	S	E	R	R	A	T	U	R	A
Ø	Ø	Ø	Ø	Ø	Ø	Ø	Ø	Ø	Ø	Ø
R	1	1	1	Ø	Ø	1	1	1	Ø	1
A	2	2	2	1	1	Ø	1	2	1	Ø
T	3	3	3	2	2	1	Ø	1	2	1

Per determinare gli allineamenti tra la **X** e le **sottosequenze di Y** si procede come in ALLINEA, risalendo dalla posizione considerata nell'ultima riga **fino alla riga Ø**

	∅	S	E	R	R	A	T	U	R	A
∅	∅	∅	∅	∅	∅	∅	∅	∅	∅	∅
R	1	1	1	∅	∅	1	1	1	∅	1
A	2	2	2	1	1	∅	1	2	1	∅
T	3	3	3	2	2	1	<u>∅</u>	1	2	<u>1</u>

$$M[3, 6] = 0$$

Y . . R A T . .
X R A T

$$M[3, 9] = 1$$

Y . . R A -
X R A T

Studiamo ora gli allineamenti tra sequenze misurandone la qualità con un nuovo parametro detto **similarità**, spesso utilizzato in biologia molecolare al posto della **edit distance**.

Come per la edit distance, la **similarità** di un allineamento è **la somma dei pesi tra coppie di caratteri corrispondenti**, ove i pesi sono definiti come:

$P(i,j) = +1$ se $x_i = y_j$ (il match ha segno positivo)

$P(i,j) = - 1$ se $x_i \neq y_j$ (mismatch ha segno negativo)

carattere-spazio ha similarità - 1

Due sequenze con data edit distance **hanno similarità tanto più alta quanto maggiore è la loro lunghezza**, poiché coincidono in un numero maggiore di posizioni e ciascuna di queste dà contributo +1 alla somma.

A A A

B A A

ed 1 sim 1

A A A A A A A A A A A A A

B A A A A A A A A A A A A

ed 1 sim 10

Vediamo come si modifica l'algoritmo di EDIT-DISTANCE impiegando la similarità

Problema di Global Comparison

Date due sequenze X e Y trovare un allineamento di massima similarità

All'opposto della edit distance, la similarità è il peso complessivo dell'allineamento che **massimizza** tale peso

Impieghiamo l'algoritmo di base sulla matrice M già impiegato per la edit distance, con **le seguenti modifiche**:

$M[i,j]$ indica la similarità tra il prefisso $x_1 x_2 \dots x_i$ di X e il prefisso $y_1 y_2 \dots y_j$ di Y contenenti eventualmente degli spazi.

$M[n,m]$ è la similarità tra le due sequenze.

La riga e la colonna $\emptyset$ della M corrispondenti a prefissi vuoti di X e Y si inizializzano come:

$$M[\emptyset, j] = -j \quad \text{per } \emptyset \leq j \leq m$$

$$M[i, \emptyset] = -i \quad \text{per } \emptyset \leq i \leq n$$

Gli elementi $M[i,j]$ si calcolano con la formula
ricorsiva (funzione **max** al posto di **min**):

$$M[i,j] = \max\{ M[i,j-1] - 1, \\ M[i-1,j] - 1, \\ M[i-1,j-1] + p(i,j) \}$$

La formula può essere immediatamente modificata
per diversi valori dei pesi

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1						
L	-2						
B	-3						
E	-4						
R	-5						
O	-6						

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	<u>-1</u>	<u>-2</u>	<u>-3</u>	<u>-4</u>
L	-2						
B	-3						
E	-4						
R	-5						
O	-6						

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	-1	-2	-3	-4
L	-2	0	-1	-1	-2	-3	-4
B	-3						
E	-4						
R	-5						
O	-6						

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	-1	-2	-3	-4
L	-2	0	-1	-1	-2	-3	-4
B	-3	-1	-1	0	0	-1	-2
E	-4						
R	-5						
O	-6						

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	-1	-2	-3	-4
L	-2	0	-1	-1	-2	-3	-4
B	-3	-1	-1	0	0	-1	-2
E	-4	-2	-2	-1	-1	-1	-2
R	-5						
O	-6						

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	-1	-2	-3	-4
L	-2	0	-1	-1	-2	-3	-4
B	-3	-1	-1	0	0	-1	-2
E	-4	-2	-2	-1	-1	-1	-2
R	-5	-3	-3	-2	-2	0	-1
O	-6						

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	-1	-2	-3	-4
L	-2	0	-1	-1	-2	-3	-4
B	-3	-1	-1	0	0	-1	-2
E	-4	-2	-2	-1	-1	-1	-2
R	-5	-3	-3	-2	-2	0	-1
O	-6	-4	-4	-3	-3	-1	+1

$M[6,6] = +1$ è la similarità tra le due sequenze

Anche per la global comparison possono esserci diversi allineamenti ottimi che si ricostruiscono con l'algoritmo già descritto per la edit distance risalendo dalla cella $M[n,m]$ alla $M[0,0]$, tenendo conto della nuova regola di calcolo di ogni cella $M[i,j]$

	0	L	A	B	B	R	O
0	0	-1	-2	-3	-4	-5	-6
A	-1	-1	0	-1	-2	-3	-4
L	-2	0	-1	-1	-2	-3	-4
B	-3	-1	-1	0	0	-1	-2
E	-4	-2	-2	-1	-1	-1	-2
R	-5	-3	-3	-2	-2	0	-1
O	-6	-4	-4	-3	-3	-1	+1

Due allineamenti con
similarità +1

A	L	-	B	E	R	O	-	A	L	B	E	R	O
-	L	A	B	B	R	O	L	A	-	B	B	R	O
-1	+1	-1	+1	-1	+1	+1	-1	+1	-1	+1	-1	+1	+1

Questi sono due degli allineamenti già trovati con
edit distance = 3

Notare che l' allineamento trovato con edit
distance = 3

A	L	B	E	R	O
L	A	B	B	R	O
-1	-1	+1	-1	+1	+1

ha similarità = 0

La similarità è anche impiegata in un problema fondamentale in biologia molecolare che si risolve attraverso la matrice M, con una variazione del solito metodo.

PATTERN COMPARISON. Ricerca con **massima similarità** di una sottosequenza **X** in una sequenza **Y** in genere molto più lunga.

L'algoritmo è una ovvia estensione di quello di **ricerca di un pattern in un testo** ove si **sostituisce la similarità** alla distanza. Si **inizializzano con zero** tutti gli elementi della prima riga e con 0, -1, -2, . . . quelli della prima colonna, e si cerca il valore di **massima similarità nell'ultima riga**.

	Y	A	T	G	T	G	A	C	G	A	A	T	C	A
X	0	0	0	0	0	0	0	0	0	0	0	0	0	0
T	-1	-1	+1	0	+1	0	-1	-1	-1	-1	-1	+1	0	-1
C	-2	-2	0	0	0	0	-1	0	-1	-2	-2	0	+2	+1
A	-3	-1	-1	-1	-1	-1	+1	0	-1	0	-1	-1	+1	+3
G	-4	-2	-2	0	-1	0	-1	0	+1	0	-1	-2	0	+2
A	-5	-3	-3	-1	-1	-1	+1	0	0	+2	+1	0	-1	+1

Massima similarità in M[5,9]

A	T	C	T	G	A	C	G	A	A	T	C	A
			T	C	A	-	G	A				
			+1	-1	+1	-1	+1	+1				

Un nuovo problema **di massima importanza**:

LOCAL COMPARISON. Tra due sequenze X, Y trovare una sottosequenza S_x di X e una sottosequenza S_y di Y che hanno un allineamento **di massima similarità**.

Il problema sembra molto più difficile dei precedenti perché non si sa nulla a priori sulle due sottosequenze cercate. Tuttavia si risolve attraverso la matrice M , con una variazione del solito metodo.

MA ATTENZIONE: LA VARIAZIONE E' SEMPLICE
MA LA SUA COMPrensione UN PO' MENO !

S_x e S_y devono essere confrontate dal loro inizio, tralasciando i caratteri che le precedono in X in Y. Dunque la prima riga e la prima colonna di M sono inizializzate con tutti zeri.

$M[i,j]$ ora indica la **massima similarità** tra due sottosequenze che terminano in i, j , cioè

$S_x = x_h \dots x_i$ e $S_y = y_k \dots y_j$ ove i valori h, k , $1 \leq h \leq i$, $1 \leq k \leq j$, rendono massima la similarità.

Come sempre nell'allineamento si possono inserire degli spazi

Osservazione chiave:

Se tutte le possibili S_x , S_y che terminano in i, j hanno **similarità negativa**, si scelgono due sottosequenze **vuote** che hanno similarità zero.

$M[i,j]$ si calcola con la formula ricorsiva (si noti lo zero tra i valori del massimo):

$$M[i,j] = \max\{M[i,j-1] - 1, \\ M[i-1,j] - 1, \\ M[i-1,j-1] + p(i,j), \\ 0\}$$

Il risultato apparirà nella cella $M[i,j]$ che ha un valore rilevante per il caso che si sta studiando (spesso **il valore massimo** nella matrice), relativa agli indici i, j di terminazione di S_x , S_y

	Y	T	A	G	A	G	T	C	G
X	0	0	0	0	0	0	0	0	0
A	0								
G	0								
T	0								
A	0								
C	0								
T	0								

	Y	T	A	G	A	G	T	C	G		
X	0	0	0	0	0	0	0	0	0		
A	0	0	+1	0	+1	0	0	0	0	X	A G T
G	0	0	0	+2	+1	+2	+1	0	+1	Y	A G T
T	0	+1	0	+1	+1	+1	+3	+2	+1	X	A G T A C
A	0	0	+2	+1	+2	+1	+2	+2	+1	Y	A G T - C
C	0	0	+1	+1	+1	+1	+1	+3	+2	X	A G T A
T	0	+1	0	0	0	0	+2	+2	+2	Y	A G - A

La ricostruzione dell'allineamento avverrà con il metodo di tracciamento all'indietro arrestandosi quando si incontra **una cella con valore zero**, che può trovarsi in qualunque punto della M