Informatica per le Biotecnologie
Algoritmica Lezione 6-1

Anzitutto ricordiamo l'algoritmo di base per l'allineamento di sequenze e il calcolo della **edit distance** (numero di differenze)

Come si calcola la matrice?

	Y	L	A	B	B	R	O
X	0	1	2	3	4	5	6
A	1	1	1	2	3	4	5
L	2	1	2	2	3	4	5
B	3	2	2	2	2	3	4
E	4	3	3	3	3	3	4
R	5	4	4	4	4	3	4
O	6	5	5	5	5	4	3

riga e colonna Ø

M[Ø,j]=j per Ø≤j≤m

M[i,Ø]=i per Ø≤i≤n

detta **p(i,j)** la distanza tra x_i e y_j

p(i,j) = 0 per $x_i = y_j$ (match)

p(i,j) = 1 per $x_i \neq y_j$ (mismatch)

carattere-spazio hanno distanza = 1

$$M[i,j] = \min\{M[i,j-1]+1,$$
$$M[i-1,j]+1,$$
$$M[i-1,j-1]+p(i,j)\}$$
$$\text{per } 1 \le i \le n,\ 1 \le j \le m$$

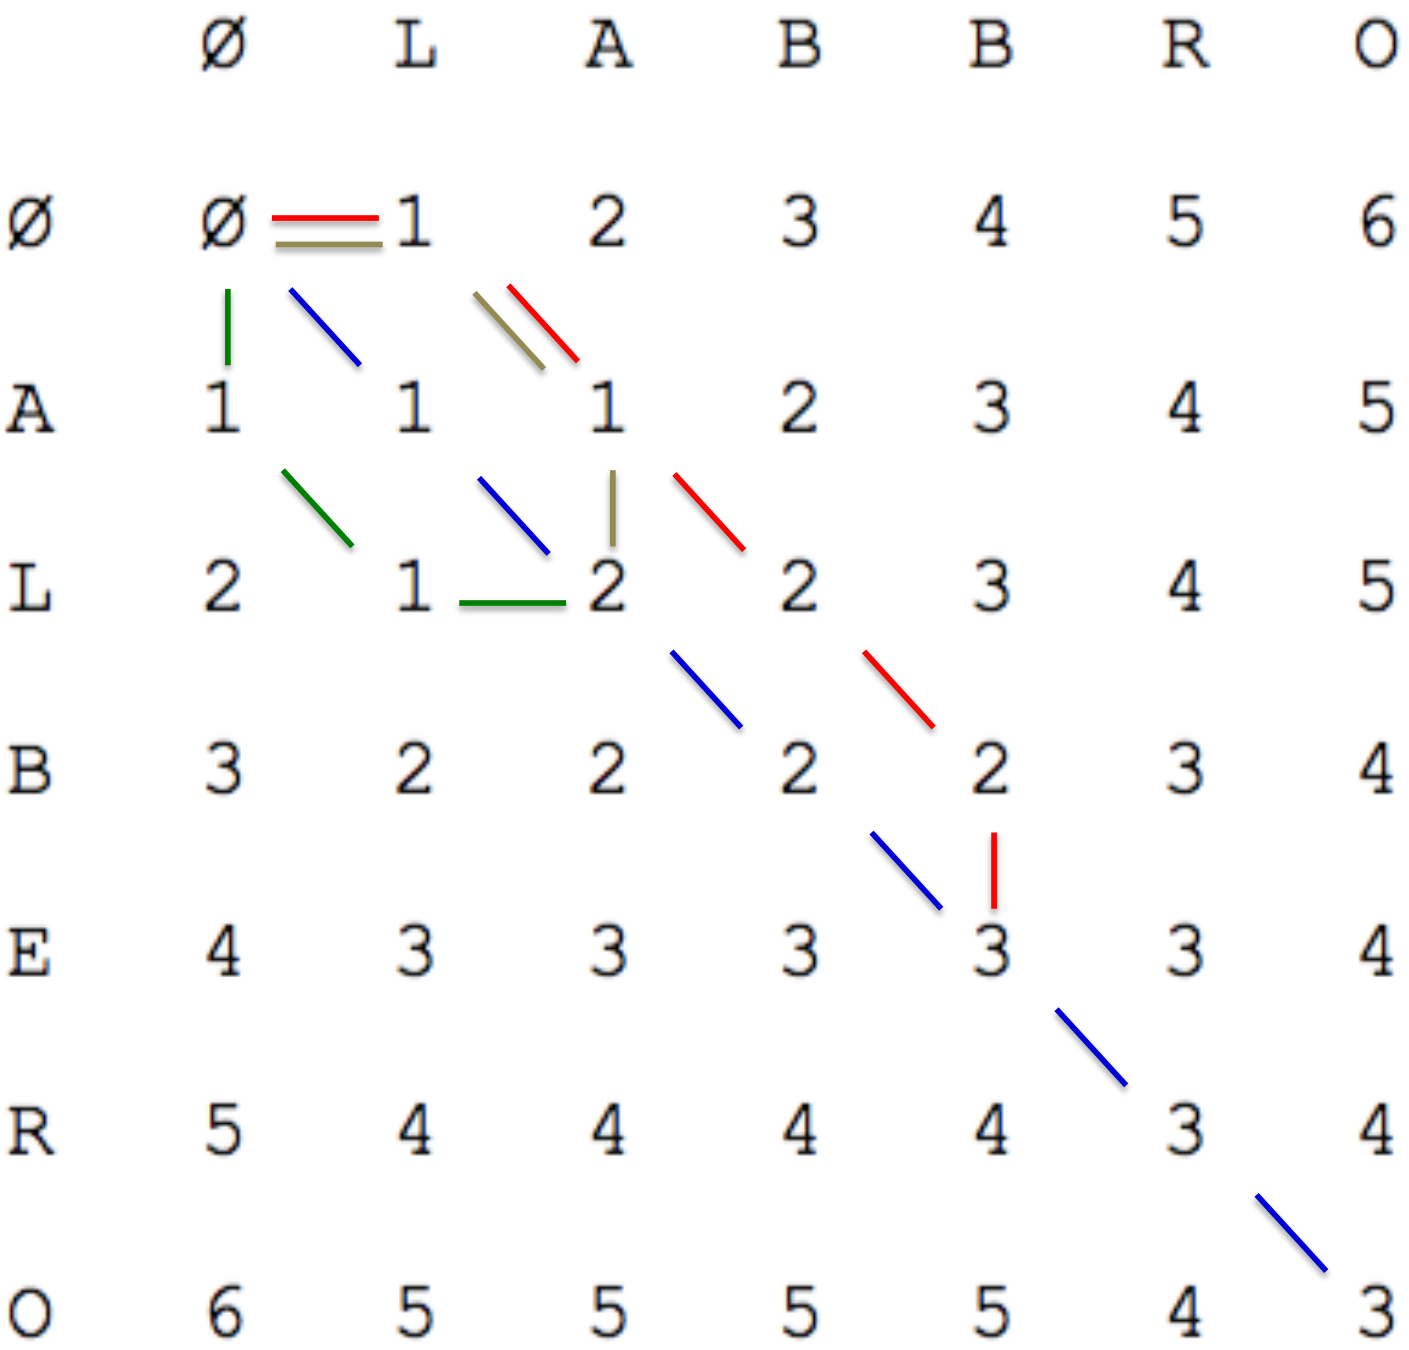
Mossa orizzontale

Mossa verticale

Mossa diagonale

	Ø	L	A	B
Ø	Ø	1	2	3
A	1	1	1	2
L	2	1	2	2
B	3	2	2	2
E	4	3	3	3

		Ø	L	A	B	B	R	O
Ø	Ø	1	2	3	4	5	6
A	1	1	1	2	3	4	5
L	2	1	2	2	3	4	5
B	3	2	2	2	2	3	4
E	4	3	3	3	3	3	4
R	5	4	4	4	4	3	4
O	6	5	5	5	5	4	3


Ø L A B B R O
Ø Ø 1 2 3 4 5 6
A 1 1 1 2 3 4 5
L 2 1 2 2 3 4 5
B 3 2 2 2 2 3 4
E 4 3 3 3 3 3 4
R 5 4 4 4 4 3 4
O 6 5 5 5 5 4 3

Come per la edit distance, la similarità di un allineamento è la somma dei pesi tra coppie di caratteri corrispondenti, ove i pesi sono definiti come:

$P(i,j) = +1$ se $x_i = y_j$ (il match ha segno positivo)

$P(i,j) = -1$ se $x_i \neq y_j$ (mismatch ha segno negativo)

carattere-spazio ha similarità - 1

Due sequenze con data edit distance hanno similarità tanto più alta quanto maggiore è la loro lunghezza, poiché coincidono in un numero maggiore di posizioni e ciascuna di queste dà contributo +1 alla somma.

```
A A A              A A A A A A A A A A A A
B A A              B A A A A A A A A A A A
ed 1 sim 1         ed 1  sim 10
```

Ricordiamo ora due importanti problemi studiati nella lezione precedente: **Pattern comparison** e **Local comparison**

PATTERN COMPARISON. Ricerca con **massima similarità** di una sottosequenza X in una sequenza Y in genere molto più lunga.

L'algoritmo è una ovvia estensione di quello di ricerca di un pattern in un testo ove si sostituisce la similarità alla edit distance. Si inizializzano con zero tutti gli elementi della prima riga e con 0, -1, -2, . . . quelli della prima colonna, e si cerca il valore di massima similarità nell'ultima riga.

	Y	A	T	G	T	G	A	C	G	A	A	T	C	A
X	0	0	0	0	0	0	0	0	0	0	0	0	0	0
T	−1	−1	+1	0	+1	0	−1	−1	−1	−1	−1	+1	0	−1
C	−2	−2	0	0	0	0	−1	0	−1	−2	−2	0	+2	+1
A	−3	−1	−1	−1	−1	−1	+1	0	−1	0	−1	−1	+1	+3
G	−4	−2	−2	0	−1	0	−1	0	+1	0	−1	−2	0	+2
A	−5	−3	−3	−1	−1	−1	+1	0	0	+2	+1	0	−1	+1

Massima similarità in M[5,9]

A	T	C	T	G	A	C	G	A	A	T	C	A
			T	C	A	-	G	A				
			+1	−1	+1	−1	+1	+1				

LOCAL COMPARISON. Tra due sequenze X, Y trovare una sottosequenza S_x di X e una sottosequenza S_y di Y che hanno un allineamento **di massima similarità.**

Il problema sembra molto più difficile dei precedenti perché non si sa nulla a priori sulle due sottosequenze cercate. Tuttavia si risolve attraverso la matrice M, con una variazione del solito metodo.

S_x e S_y devono essere confrontate dal loro inizio, tralasciando i caratteri che le precedono in X in Y. Dunque la prima riga e la prima colonna di M sono inizializzate con tutti zeri.

M[i,j] ora indica la massima similarità tra due sottosequenze che terminano in i, j , cioè
$S_x = x_h \ldots x_i$ e $S_y = y_k \ldots y_j$ ove i valori h, k,
$1 \leq h \leq i$, $1 \leq k \leq j$, rendono massima la similarità.

Come sempre nell'allineamento si possono inserire degli spazi

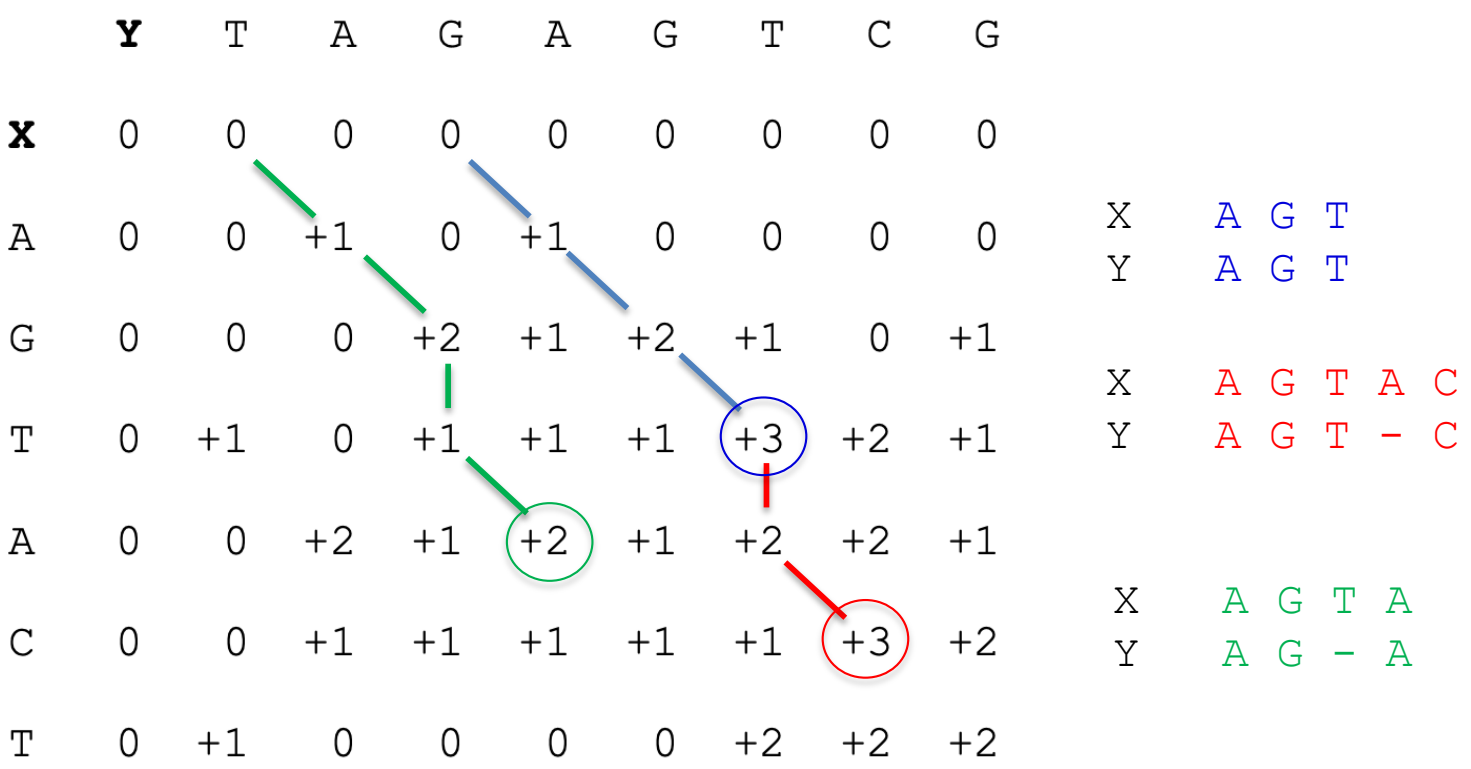
Osservazione chiave:
Se tutte le possibili S_x , S_y che terminano in i , j hanno similarità negativa, si scelgono due sottosequenze vuote che hanno similarità zero.

M[i,j] si calcola con la formula ricorsiva (si noti lo zero tra i valori del massimo):

```
M[i,j] = max{M[i,j-1] - 1,
             M[i-1,j] - 1,
             M[i-1,j-1] + p(i,j),
             0}
```

Il risultato apparirà nella cella M[i,j] che ha un valore rilevante per il caso che si sta studiando (spesso il valore massimo nella matrice), relativa agl'indici i, j di terminazione di S_x , S_y

	Y	T	A	G	A	G	T	C	G
X	0	0	0	0	0	0	0	0	0
A	0								
G	0								
T	0								
A	0								
C	0								
T	0								



La ricostruzione dell'allineamento avverrà con il metodo di tracciamento all'indietro arrestandosi quando si incontra una cella con valore zero, che può trovarsi in qualunque punto della M

E ora un nuovo fondamentale problema

Fragment assembly

Ricostruzione di una sequenza di DNA sulla base della conoscenza di alcuni (moltissimi) **frammenti**.
Il problema nel complesso è detto **sequenziamento**.

Consideriamo sequenze di quattro basi:
A, G - purine, C, T - pirimidine.
Le sequenze sono orientate come nella stuttura della molecola e riferite a uno dei due filamenti.

Gli esperimenti per *leggere* i filamenti di DNA sono in grado di operare su sequenze lunghe fino a qualche migliaio di basi.

Inoltre è oggi tecnicamente impossibile ottenere un intero filamento di DNA senza che questo si rompa in un grande numero di frammenti, anche per organismi la cui intera sequenza è breve.

FRAGMENT ASSEMBLY. Dato un insieme di frammenti di una sequenza, tra loro indipendenti (cioè derivanti da parti distinte della sequenza) o parzialmente sovrapponibili (cioè derivanti da parti interamente o parzialmente sovrapposte), ricostruire la sequenza originale con il minimo numero di errori.

Per eseguire il sequenziamento i frammenti devono essere moltissimi e presentare moltissime sovrapposizioni. Ciò è ottenuto mediante PCR con cui da una molecola di DNA si ottengono repliche in numero che cresce esponenzialmente nel tempo.

Si noti che se tutti i segmenti fossero disgiunti non si avrebbe modo di stabilire in che ordine assembrarli.

Un esempio elementare: quattro brevissimi frammenti

```
T C C G A     C G A C T
A A T C     A T C C G A
```

e l’indicazione che la sequenza complessiva deve contenere circa dieci basi (dunque devono esserci sovrapposizioni di segmenti).

Un possibile allineamento e la risultante sequenza di **consenso**

```
- - T C C G A - -
- - - - C G A C T
A A T C - - - - -
- A T C C G A - -
_________________
A A T C C G A C T
```

È un caso ideale senza errori.

In genere gli errori sono inevitabili e dipendono dagli strumenti di lettura delle basi e dalla possibile imprecisa replicazione nella PCR.

Errore nel secondo frammento:

C C A C T anziché C G A C T

```
- - T C C G A - -
- - - - C C A C T
A A T C - - - - -
- A T C C G A - -
_________________
A A T C C G A C T
```

stesso allineamento

G scelta a maggioranza

Errore nel quarto frammento:

A T C G A anziché A T C C G A

(perdita della terza o quarta base)

```
- - T C C G A - -
- - - - C G A C T
A A T C - - - - -
- A T C - G A - -
_________________
A A T C C G A C T
```

stesso allineamento con spazio nella quarta sequenza e C scelta a maggioranza

Errore nel secondo frammento:

C T G A C T anziché C G A C T

(inserzione nella seconda base)

```
- - T C C - G A - -
- - - - C T G A C T
A A T C - - - - - -
- A T C C - G A - -
_____________________
A A T C C - G A C T
```

diverso allineamento con spazi nella prima e quarta sequenza e spazio nel consenso scelto a maggioranza (ma non vi sono spazi agli estremi del consenso)

Vi sono casi più complessi, a cui solo accenniamo

- Due frammenti provenienti da parti distanti della sequenza originale e parzialmente sovrapponibili, si connettono tra loro dando luogo a un tratto di sequenza detta **chimera**.

Le chimere vanno escluse dalla sequenza ricostruita con tecniche specifiche.

- La sequenza originale può avere tratti ripetuti

detti **repeat**. Per esempio nella sequenza **S**:

S = T_1 a b c T_2 a b c T_3 a b c T_4

T_1, T_2, T_3, T_4 sono tratti diversi, e **R** = a b c è un repeat composto da tre sotto-sequenze a, b, c.

Da eventuali frammenti

$\mathbf{F_1}$ = c T_2 a $\mathbf{F_2}$ = c T_3 a

il consenso può risultare:

$\mathbf{S_1}$ = T_1 **R** T_2 **R** T_3 **R** T_4 corretta

$\mathbf{S_2}$ = T_1 **R** T_3 **R** T_2 **R** T_4 non corretta

- **Mancanza di copertura**: mancano i frammenti relativi a tratti della sequenza originale.

Si ricostruiscono porzioni disgiunte del consenso

l'unico rimedio è ripetere le operazioni su un maggior numero di copie della sequenza, tenendo presente che i costi complessivi crescono col numero di frammenti costruiti.

Ricostruire la sequenza non è semplice data l'assenza di informazioni sulle zone della sequenza da cui provengono i frammenti e la parziale sovrapposizione tra essi.

Un problema di base, cuore dell'intero processo, si risolve come estensione dei precedenti, in particolare della local comparison.

SUFFIX-PREFIX COMPARISON.

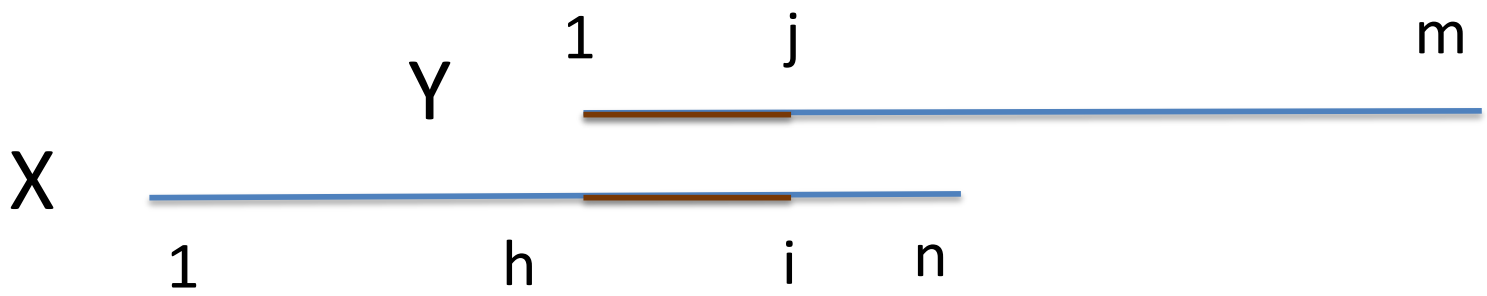
Date due sequenze X,Y trovare un suffisso S_X di X e un prefisso P_y di Y che presentino la **massima similarità.**

Infatti due frammenti si compongono sovrapponendo una parte finale (suffisso) di uno a una parte iniziale (prefisso) del'altro.

Ma non si conosce a priori la lunghezza delle sotto-sequenze S_X e P_y cercate (cioè in quali punti di X e Y inizia la prima e termina la seconda)

Adottiamo di nuovo i pesi p[i,j] = +1 o -1 per match o mismatch, e peso -1 per carattere-spazio, e impieghiamo l'algoritmo standard sulla matrice M con le seguenti variazioni.

- Il valore M[i,j] indica la massima similarità tra un tratto $x_h \ldots x_i$ di X, e un prefisso $y_1 \ldots y_j$ di Y.



Inizializzazione:

$M[Ø,j] = -j$, per $Ø \leq j \leq m$

possibili spazi iniziali prima di S_X

$M[i,Ø] = Ø$, per $Ø \leq i \leq n$

S_X può iniziare in ogni posizione di X

La formula ricorsiva è quella relativa alla global comparison

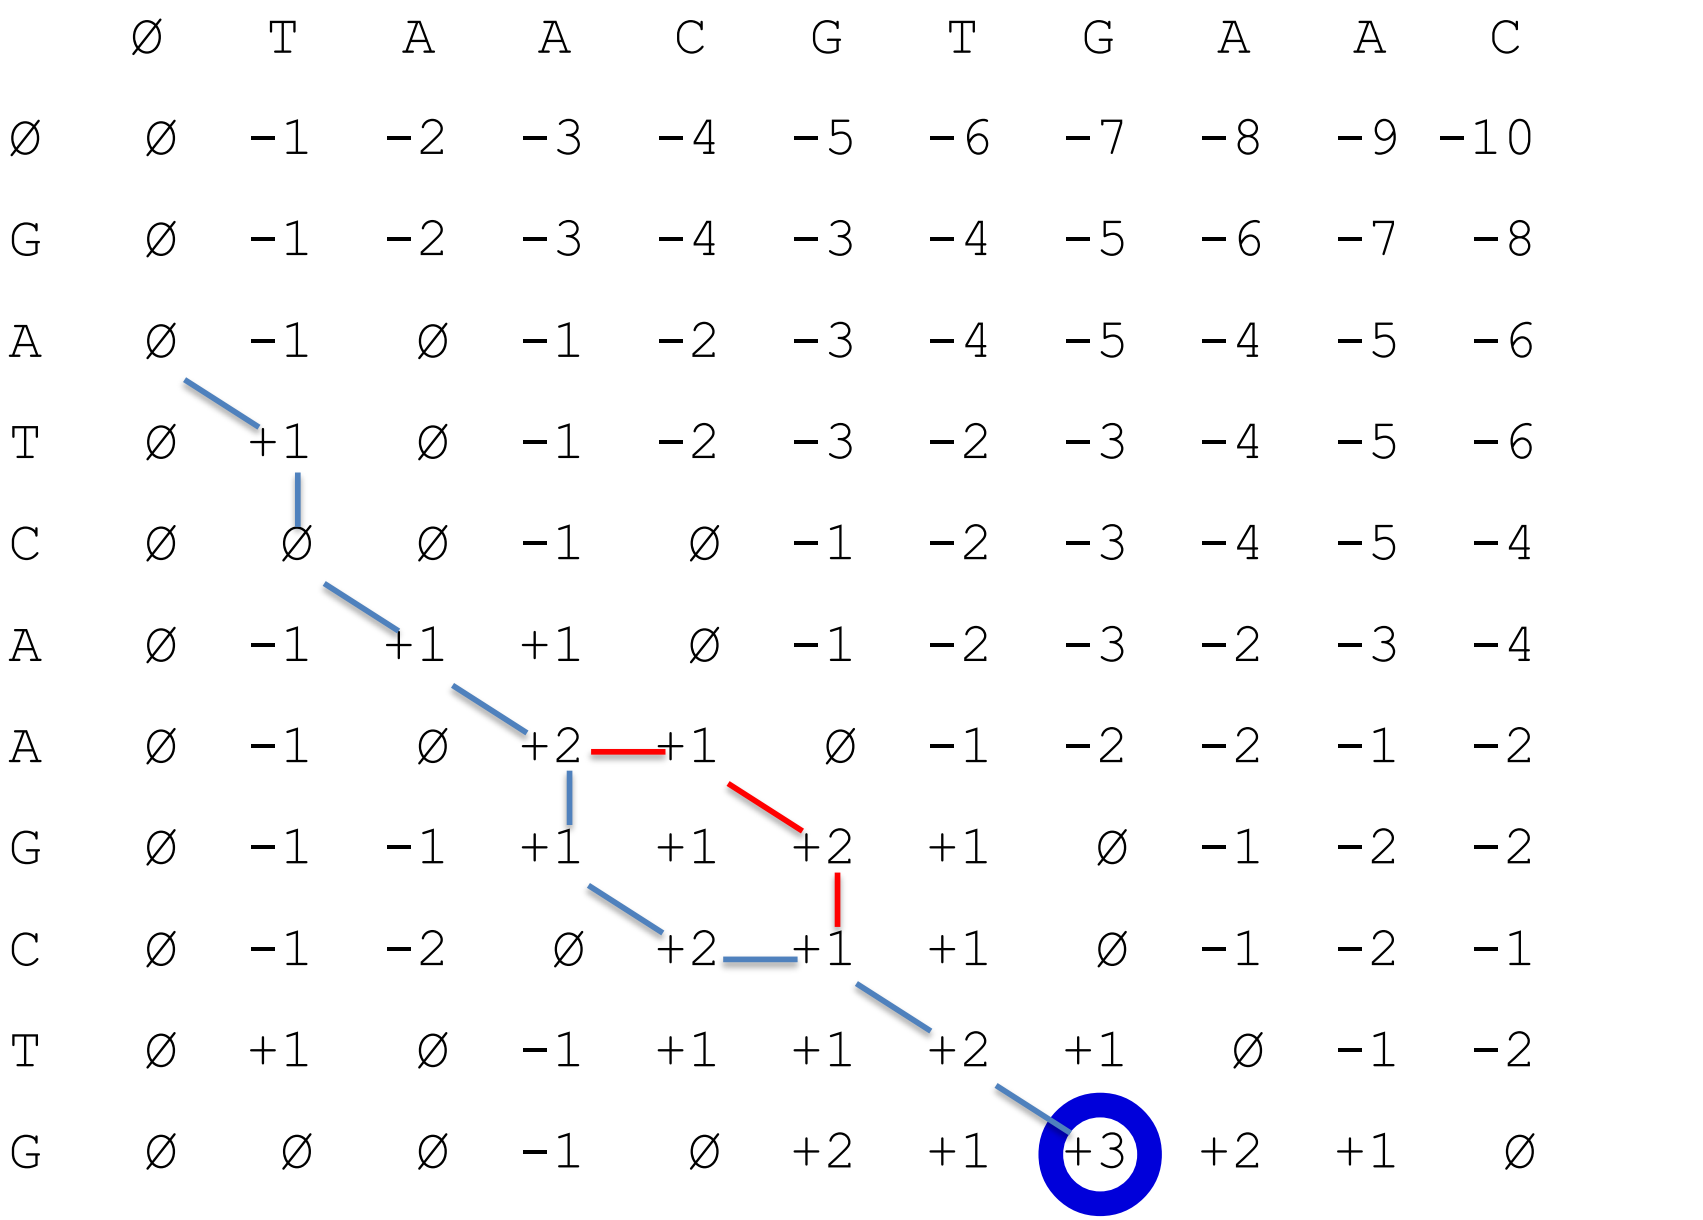
$$\mathbf{M[i,j] = \max\{M[i,j-1]-1,\ M[i-1,j]-1,\ M[i-1,j-1]+p(i,j)\}}$$

I risultati si cercano nell'ultima riga della matrice: M[n,j] indica che l'esame di un suffisso S_X è stato completato paragonandolo al prefisso P_y che termina nella colonna j.

L'allineamento si costruisce risalendo nella matrice fino a raggiungere la colonna zero, nella riga ove il prefisso S_X ha inizio, a parte eventuali spazi iniziali.

	Ø	T	A	A	C	G	T	G	A	A	C
Ø	Ø	-1	-2	-3	-4	-5	-6	-7	-8	-9	-10
G	Ø	-1	-2	-3	-4	-3	-4	-5	-6	-7	-8
A	Ø	-1	Ø	-1	-2	-3	-4	-5	-4	-5	-6
T	Ø	+1	Ø	-1	-2	-3	-2	-3	-4	-5	-6
C	Ø	Ø	Ø	-1	Ø	-1	-2	-3	-4	-5	-4
A	Ø	-1	+1	+1	Ø	-1	-2	-3	-2	-3	-4
A	Ø	-1	Ø	+2	+1	Ø	-1	-2	-2	-1	-2
G	Ø	-1	-1	+1	+1	+2	+1	Ø	-1	-2	-2
C	Ø	-1	-2	Ø	+2	+1	+1	Ø	-1	-2	-1
T	Ø	+1	Ø	-1	+1	+1	+2	+1	Ø	-1	-2
G	Ø	Ø	Ø	-1	Ø	+2	+1	+3	+2	+1	Ø

M[10,7] = +3


Ø T A A C G T G A A C
Ø Ø -1 -2 -3 -4 -5 -6 -7 -8 -9 -10
G Ø -1 -2 -3 -4 -3 -4 -5 -6 -7 -8
A Ø -1 Ø -1 -2 -3 -4 -5 -4 -5 -6
T Ø +1 Ø -1 -2 -3 -2 -3 -4 -5 -6
C Ø Ø Ø -1 Ø -1 -2 -3 -4 -5 -4
A Ø -1 +1 +1 Ø -1 -2 -3 -2 -3 -4
A Ø -1 Ø +2 +1 Ø -1 -2 -2 -1 -2
G Ø -1 -1 +1 +1 +2 +1 Ø -1 -2 -2
C Ø -1 -2 Ø +2 +1 +1 Ø -1 -2 -1
T Ø +1 Ø -1 +1 +1 +2 +1 Ø -1 -2
G Ø Ø Ø -1 Ø +2 +1 +3 +2 +1 Ø

M[10,7] = +3

```
Y:       T - A A - C G T G A A C
X:   G A T C A A G C - T G
```

```
Y:       T - A A C G - T G A A C
X:   G A T C A A - G C T G
```

Due allineamenti con similarità 3 e lughezza 9

Nelle applicazioni biologiche una sovrapposizione accettabile deve avere in genere lunghezza k e similarità s relativamente alte.

Tra due sovrapposizioni con valori (k_1,s_1) e (k_2,s_2) tali che $k_1 > k_2$ e $s_1 < s_2$ il criterio di scelta è stabilito dal biologo.

Nelle sequenze geniche degli eucarioti, i frammenti possono contenere migliaia di basi e le sovrapposizioni tra loro devono contenere fino a centinaia di basi, con un numero massimo di differenze di qualche unità.